

# Apuntes: Cauchy–Schwarz, Formas Cuadráticas y Proyección Ortogonal

## 1. La forma cuadrática asociada

Sea  $(H, \langle \cdot, \cdot \rangle)$  un espacio de Hilbert. Para  $f, g \in H$  definimos

$$Q(\lambda) = \|f - \lambda g\|^2, \quad \lambda \in \mathbb{C}.$$

Expandiendo con el producto interno:

$$Q(\lambda) = \|f\|^2 - 2\Re(\lambda \langle f, g \rangle) + |\lambda|^2 \|g\|^2.$$

Es decir,  $Q(\lambda)$  es una *parábola* en la variable  $\lambda$ .

## 2. Optimización

Como  $Q(\lambda) \geq 0$  para todo  $\lambda$ , el valor mínimo se alcanza en

$$\lambda^* = \frac{\langle f, g \rangle}{\|g\|^2}.$$

Sustituyendo:

$$Q(\lambda^*) = \|f\|^2 - \frac{|\langle f, g \rangle|^2}{\|g\|^2}.$$

## 3. Desigualdad de Cauchy–Schwarz

De la positividad se sigue:

$$Q(\lambda^*) \geq 0 \implies |\langle f, g \rangle|^2 \leq \|f\|^2 \|g\|^2.$$

Esto es precisamente la **desigualdad de Cauchy–Schwarz**.

## 4. Interpretación geométrica

- $Q(\lambda)$  representa la **distancia al cuadrado** entre  $f$  y el subespacio generado por  $g$ :

$$Q(\lambda) = \|f - \lambda g\|^2.$$

- El mínimo  $Q(\lambda^*)$  corresponde a la **distancia ortogonal** de  $f$  al subespacio  $\text{span}\{g\}$ .
- El vector proyectado es

$$P_g(f) = \lambda^* g = \frac{\langle f, g \rangle}{\|g\|^2} g.$$

- El residuo  $f - P_g(f)$  es ortogonal a  $g$ :

$$\langle f - P_g(f), g \rangle = 0.$$

## 5. Continuidad

La función  $Q(\lambda)$  es cuadrática y por tanto continua en  $\lambda$ . Esto garantiza que el paso al mínimo no requiere argumentos de límite  $\varepsilon$ - $\delta$ , sino que la geometría misma del espacio de Hilbert asegura la continuidad y la convergencia.

## 6. Aplicaciones en Machine Learning

La desigualdad de Cauchy-Schwarz y la interpretación de la forma cuadrática aparecen en múltiples áreas de Machine Learning:

### 6.1 Similitud de coseno

Para embeddings  $x, y \in \mathbb{R}^n$ , se define

$$\cos(\theta) = \frac{\langle x, y \rangle}{\|x\| \|y\|}.$$

Cauchy-Schwarz garantiza que  $-1 \leq \cos(\theta) \leq 1$ , haciendo válida la noción de similitud usada en NLP, visión y sistemas de recomendación.

### 6.2 Regularización y estabilidad

En problemas de optimización se minimiza

$$\min_w L(w) + \lambda \|w\|^2,$$

donde la norma proviene de un producto interno. Cauchy-Schwarz asegura continuidad y estabilidad de los algoritmos de gradiente.

## 6.3 Kernels y SVMs

Si  $K(x, y)$  es un kernel en un espacio de Hilbert reproducing (RKHS),

$$|K(x, y)| \leq \sqrt{K(x, x)} \sqrt{K(y, y)}.$$

Esto valida el kernel como medida de similitud y sustenta métodos como SVMs y Gaussian Processes.

## 6.4 Acotación de errores

Para variables aleatorias  $X, Y$ ,

$$|\mathbb{E}[XY]| \leq \sqrt{\mathbb{E}[X^2]} \sqrt{\mathbb{E}[Y^2]}.$$

Este bound se usa en análisis de varianza, consistencia de estimadores y teoría de generalización (PAC learning).

## 6.5 Gradiente y optimización

En descenso de gradiente,

$$|\langle \nabla f(w), d \rangle| \leq \|\nabla f(w)\| \cdot \|d\|.$$

Esto garantiza que el gradiente actúa como un funcional lineal continuo y que el paso en dirección  $d$  está controlado.

## 6.6 PCA y reducción de dimensionalidad

En PCA se maximiza

$$\max_{\|v\|=1} v^T \Sigma v,$$

donde  $\Sigma$  es la matriz de covarianza. El máximo se alcanza en un autovector principal gracias a Cauchy–Schwarz, lo que fundamenta la reducción de dimensionalidad.

**Conclusión:** La desigualdad de Cauchy–Schwarz puede verse como la afirmación de que la parábola

$$Q(\lambda) = \|f - \lambda g\|^2$$

**nunca desciende bajo el eje horizontal.** De esta manera, Cauchy–Schwarz no sólo es una desigualdad algebraica, sino también una expresión de la *continuidad geométrica* de la proyección ortogonal.